



Curso IA desde Cero

Dr. Irvin Hussein López Nava
M.C. Joan M. Raygoza Romero

Departamento de Ciencias de la Computación
Centro de Investigación Científica y de Educación Superior de Ensenada
Edición 2026

Cartel promocional del curso "IA desde Cero: Un Curso Práctico". El cartel tiene un fondo colorido con ilustraciones de un escritorio con un monitor que muestra un diagrama de red neuronal, un robot pequeño, una bombilla, y una casa clásica. Hay varios íconos flotantes como "AI", "OBJECT RECOGNITION", y "A".

CICESE EDUCACIÓN CONTINUA | FÍSICA APLICADA


IA desde Cero:

Un Curso Práctico


Fechas: Del **4 de mayo** al **3 de junio**
Costo de Recuperación \$1,200 pesos
¿Te interesa asistir?
Escribe al siguiente correo o escanea el QR

cursosdfa@cicese.edu.mx


Un primer caso



Clasificador general




Algoritmos de inferencia



Algoritmos de inferencia



Ejemplo: salir a jugar tenis



Decision tree

- Un **árbol de decisión** representa una función que toma como entrada un vector de valores de atributos y devuelve una "decisión", i.e., un único valor de salida.
- Los valores de entrada y salida pueden ser **discretos** o **continuos**.
- Representación de un árbol de decisión:
 - Cada **nodo interno** prueba un atributo
 - Cada **rama** corresponde a un valor de atributo
 - Cada **nodo hoja** asigna una clasificación

¿Cuándo considerar los árboles de decisión?

- Instancias descriptibles por pares atributo-valor.
- La función objetivo es discreta.
- Puede ser necesaria una hipótesis disyuntiva.
- Datos de entrenamiento posiblemente ruidosos.

Ejemplos:

- Diagnóstico médico.
- Análisis de riesgo de crédito y detección de fraudes.
- Predicción de retención de empleados.
- Recomendación de productos.

Árboles de decisión

- El algoritmo básico de aprendizaje de árboles de decisión, como el ID3 (Quinlan 1986) y su sucesor C4.5 (Quinlan 1993), utiliza una búsqueda codiciosa (*greedy*) de **arriba hacia abajo** a través del espacio de posibles árboles de decisión.
- Este enfoque comienza con la pregunta de qué atributo debe ser probado en la raíz del árbol.
 - Para decidir esto, cada atributo se evalúa mediante una prueba estadística para determinar qué tan bien clasifica los ejemplos de entrenamiento.

Árboles de decisión

- El **mejor atributo** se selecciona para ser probado en la raíz del árbol.
- Después, se crea un **nodo descendiente** para cada valor posible de este atributo, y los ejemplos de entrenamiento se distribuyen al nodo correspondiente según su valor.
- Este proceso se repite **recursivamente** en cada **nodo descendiente**, seleccionando el **mejor atributo** en cada punto del árbol, lo que constituye una búsqueda *greedy* sin retroceso para construir un árbol de decisión aceptable.


¿Cuál atributo es el mejor clasificador?

- Se desea elegir el atributo más útil para **clasificar** los ejemplos, ¿cuál es una buena medida cuantitativa del valor de un atributo?
- La propiedad estadística llamada **ganancia de información**, mide qué tan bien un atributo separa los ejemplos de entrenamiento según su clasificación objetivo.
 - ID3 utiliza esta medida para seleccionar entre los atributos candidatos en cada paso mientras construye el árbol.

Entropía

- **S** es una muestra de ejemplos de entrenamiento.
- **S+** es la proporción de ejemplos positivos en S.
- **S-** es la proporción de ejemplos negativos en S.
- La **entropía** mide la impureza de S.

$$Entropy(S) \equiv -S_{\oplus} \log_2 S_{\oplus} - S_{\ominus} \log_2 S_{\ominus}$$



Aplicando la Entropía

- Para ilustrar esto, suponga que S es una colección de 14 ejemplos de algún concepto booleano, incluidos 9 ejemplos positivos y 5 negativos (adoptando la notación $[9+, 5-]$ para resumir dicha muestra de datos).
- Entonces, la entropía de S relativa a esta clasificación booleana es

$$Entropy(S) \equiv \sum_{i=1}^c -p_i \log_2 p_i$$

$$Entropy([9+, 5-]) = -(9/14) \log_2(9/14) - (5/14) \log_2(5/14) = 0.940$$

Ganancia de información

- $Gain(S, A)$ = reducción esperada de entropía debido a la clasificación en A causada por la partición de los ejemplos según este atributo.

$$Gain(S, A) \equiv Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$


donde $Values(A)$ es el conjunto de todos los valores posibles para el atributo A , y S_v es el subconjunto de S para el que el atributo A tiene valor v .

- Note que el primer término de la ecuación es la entropía de la colección original S , y el segundo término es el valor esperado de la entropía después de que S se particione utilizando el atributo A .


Attributes					
Δ day	Δ outlook	Δ temp	Δ humidity	Δ wind	✓ play
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Seleccionar el atributo siguiente

- ¿Cuál es el mejor atributo para clasificar?



$$\begin{aligned} \text{Gain}(S, \text{Humidity}) &= .940 - (7/14) \cdot .985 - (7/14) \cdot .592 \\ &= .151 \end{aligned}$$




$$\begin{aligned} \text{Gain}(S, \text{Wind}) &= .940 - (8/14) \cdot .811 - (6/14) \cdot 1.0 \\ &= .048 \end{aligned}$$

Calcular

Outlook?

Temperature?

¿y el que sigue?




$$S_{\text{Sunny}} = \{D1, D2, D8, D9, D11\}$$

- $\text{Gain}(S_{\text{Sunny}} \mid \text{Temperature}) =$
- $\text{Gain}(S_{\text{Sunny}} \mid \text{Humidity}) =$
- $\text{Gain}(S_{\text{Sunny}} \mid \text{Wind}) =$

Δ day	Δ outlook	Δ temp	Δ humidity	Δ wind	✓ play
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No


¿y el que sigue?



$$S_{Sunny} = \{D1, D2, D8, D9, D11\}$$

- $Gain(S_{Sunny}, Temperature) = 0.97 - (2/5) 0.0 - (2/5) 1.0 - (1/5) 0.0 = 0.57$
- $Gain(S_{Sunny}, Humidity) =$
- $Gain(S_{Sunny}, Wind) =$

¿y el que sigue?




Calcular

Rain


$$S_{\text{Sunny}} = \{D1, D2, D8, D9, D11\}$$

- $\text{Gain}(S_{\text{Sunny}} \mid \text{Temperature}) = 0.97 - (2/5) 0.0 - (2/5) 1.0 - (1/5) 0.0 = 0.57$
- $\text{Gain}(S_{\text{Sunny}} \mid \text{Humidity}) = 0.97 - (3/5) 0.0 - (2/5) 0.0 = 0.97$
- $\text{Gain}(S_{\text{Sunny}} \mid \text{Wind}) = 0.97 - (2/5) 1.0 - (3/5) 0.91 = 0.019$

Ejemplo: salir a jugar tenis



Just a random forest...



Bosques aleatorios

- Los **árboles de decisión** son modelos base muy populares para los métodos de ensamble.
- Los 'aprendices fuertes' compuestos por varios árboles se denominan bosques (***forests***).
- Los árboles que componen un bosque pueden ser superficiales o *shallow* (poca profundidad), o profundos (mucha profundidad).
 - Los árboles poco profundos tienen menos varianza pero mayor sesgo, por lo que son la mejor opción para los **métodos secuenciales**.
 - Los árboles profundos tienen un sesgo bajo, pero una varianza alta, por lo que son una opción adecuada para *bagging*.

Random Forest

- El enfoque de 'bosques aleatorios' es un método basado en *bagging* en el que se combinan árboles profundos, ajustados en muestras *bootstrap*, para producir un resultado con menor varianza.
- *Random forest* también utiliza otro truco para hacer que los múltiples árboles ajustados estén un poco menos correlacionados entre sí:
 - al hacer crecer cada árbol, en lugar de muestrear sólo sobre las observaciones para generar un *bootstrap*, **muestrea sobre las características** y utiliza sólo un subconjunto aleatorio de ellas para construir el árbol.

Random Forest

- El **muestreo sobre características** hace que todos los árboles no tengan exactamente la misma información y reduce la correlación entre los distintos resultados devueltos.
- Otra ventaja es que hace que el proceso de toma de decisiones sea más robusto frente a los datos que faltan.
- *Random forest* combina los conceptos de *bagging* y selección aleatoria de subespacios de características para crear modelos más robustos.




Dataset inicial

Muestras
bootstrap + Características
seleccionadas

Árboles profundos ajustados a
cada muestra *bootstrap* y
considerando sólo las
características seleccionadas

Random forest
(promedio de los árboles)

Algoritmos de inferencia





BAYES THEOREM

$$\overset{\text{Posterior probability}}{p(A|B)} = \frac{\overset{\text{Likelihood}}{p(B|A)} \overset{\text{Prior probability}}{p(A)}}{p(B)}$$



BAE'S THEOREM

$$P(\text{chill}|\text{Netflix}) = \frac{P(\text{Netflix}|\text{chill})P(\text{chill})}{P(\text{Netflix})}$$

Teorema de Bayes

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

- $P(h)$ = probabilidad previa de la hipótesis h , i.e. *a priori*.
- $P(D)$ = probabilidad previa de los datos de entrenamiento D , i.e. evidencia.
- $P(h|D)$ = probabilidad de h dado D , i.e. *a posteriori*.
- $P(D|h)$ = probabilidad de D dado h , i.e. verosimilitud.

Clasificador Naive Bayes

- Junto con los árboles de decisión, las redes neuronales y los k-vecinos más cercanos, es uno de los métodos de aprendizaje más prácticos.
- Cuándo usar:
 - Conjunto de entrenamiento moderado o grande.
 - Los atributos que describen las instancias son **condicionalmente independientes** dada una clasificación.
- Algunas aplicaciones exitosas:
 - Diagnóstico médico.
 - Clasificación de documentos de texto.

Formulación

- Suponga funciones objetivo $f: X \rightarrow V$, donde cada instancia x se describe mediante los atributos $\{a_1, a_2, \dots, a_n\}$. El valor más probable de $f(x)$ es:

$$\begin{aligned} v_{MAP} &= \arg \max_{v \in V} P(v_j | a_1, a_2, \dots, a_n) \\ v_{MAP} &= \arg \max_{v \in V} \frac{P(a_1, a_2, \dots, a_n | v_j) P(v_j)}{P(a_1, a_2, \dots, a_n)} \\ &= \arg \max_{v \in V} P(a_1, a_2, \dots, a_n | v_j) P(v_j) \end{aligned}$$

- Suposición ingenua de Bayes: $P(a_1, a_2, \dots, a_n | v_j) = \prod_i P(a_i | v_j)$
- lo que da un clasificador Naive Bayes: $v_{NB} = \arg \max_{v \in V} P(v_j) \prod_i P(a_i | v_j)$

Algoritmo Naive Bayes

Naive_Bayes_Learn(examples)

For each target value v_j

$$\hat{P}(v_j) \leftarrow \text{estimate } P(v_j)$$

For each attribute value a_i of each attribute a

$$\hat{P}(a_i|v_j) \leftarrow \text{estimate } P(a_i|v_j)$$

Classify_New_Instance(x)

$$v_{NB} = \arg \max_{v_j \in V} \hat{P}(v_j) \prod_{a_i \in x} \hat{P}(a_i|v_j)$$

Nuestro ejemplo

Δ day ≡	Δ outlook ≡	Δ temp ≡	Δ humidity ≡	Δ wind ≡	✓ play ≡
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No


Nuestro ejemplo con Naive Bayes

- Considere una nueva instancia:
- {outlook = sunny, temperature = cool, humidity = high, wind = strong}
- Se quiere calcular:
$$v_{NB} = \arg \max_{v_j \in V} P(v_j) \prod_i P(a_i | v_j)$$
- $P(y) P(sol | y) P(frío | y) P(alto | y) P(fuerte | y) =$
- $P(n) P(sol | n) P(frío | n) P(alto | n) P(fuerte | n) =$
- $v_{NB} = ?$


Nuestro ejemplo con Naive Bayes

- Considere una nueva instancia:
- {outlook = sunny, temperature = cool, humidity = high, wind = strong}
- Se quiere calcular:
$$v_{NB} = \arg \max_{v_j \in V} P(v_j) \prod_i P(a_i | v_j)$$
- $P(y) P(sol | y) P(frío | y) P(alto | y) P(fuerte | y) = 0,005$
- $P(n) P(sol | n) P(frío | n) P(alto | n) P(fuerte | n) = 0,021$
- $v_{NB} = n$

Ejemplo: salir a jugar tenis



Algoritmos de inferencia




Dime con quien andas




y te diré quién eres...

Métodos paramétricos

- Construyen una descripción general explícita de la función objetivo f .
 - El modelo resume los datos a través de una colección de parámetros.
 - Número fijo de parámetros.
 - Independiente del número de instancias en los datos de entrenamiento.




(a)



(b)


Métodos paramétricos



Métodos NO-paramétricos

- No hace suposiciones sobre la función objetivo.
 - Libertad para elegir cualquier función a partir de los datos de entrenamiento.
 - Requieren muchos más datos para estimar la función objetivo.
- Entradas similares tienen salidas similares.
 - Es una suposición razonable: El mundo es suave y las funciones, ya sean densidades, discriminantes o funciones de regresión, cambian lentamente.

Métodos NO-paramétricos



Métodos paramétricos vs no-paramétricos

- Los métodos **no paramétricos** también se denominan algoritmos de aprendizaje perezoso (*lazy*), porque a diferencia de los modelos paramétricos ansiosos (*eager*), no calculan un modelo cuando se les da el conjunto de entrenamiento, sino que posponen el cálculo hasta que se les da una instancia de consulta.

Idea principal

Vecino más próximo (*nearest neighbor*):

- Dada la instancia de consulta $x_{q'}$, primero se localiza el ejemplo de entrenamiento más cercano x_n , después se estima $\hat{f}(x_q) \leftarrow f(x_n)$

k-vecinos más próximos (*k-nearest neighbor*):

- Dado $x_{q'}$, se vota entre sus k vecinos más cercanos (si la función objetivo es de valor discreto), o
- Se toma la media de los valores f de los k vecinos más cercanos (si son de valor real).

$$\hat{f}(x_q) \leftarrow \frac{\sum_{i=1}^k f(x_i)}{k}$$



Suposiciones iniciales

Todas las instancias corresponden a puntos en un espacio n -dimensional R^n .

- Los vecinos más cercanos de una instancia se definen en términos de la distancia euclidiana estándar.
- Sea una instancia arbitraria x descrita por el vector de características $(a_1(x), a_2(x), \dots, a_n(x))$ donde $a_r(x)$ denota el valor del r -ésimo atributo de la instancia x .
- La distancia entre dos instancias x_i y x_j se define como

$$d(x_i, x_j) = \sqrt{\sum_{r=1}^n (a_r(x_i) - a_r(x_j))^2}$$

Límites de decisión de kNN



Ejemplo: weather.numeric


Training Set

					
0		85	85	0	No
1		80	90	1	No
2		83	78	0	Yes
3		70	96	0	Yes
4		68	80	0	Yes
5		65	70	1	No
6		64	65	1	Yes
7		72	95	0	No
8		69	70	0	Yes
9		75	10	0	Yes
10		75	70	1	Yes
11		72	90	1	Yes
12		81	75	0	Yes
13		71	80	1	No



Test Set

					
14		81	88	1	No
15		74	92	0	Yes
16		76	85	0	Yes
17		78	75	1	No
18		82	92	0	No
19		67	90	1	No
20		85	85	1	Yes
21		73	88	0	Yes
22		88	65	1	Yes
23		77	70	0	Yes
24		79	60	0	Yes
25		80	95	1	Yes
26		66	70	0	No
27		84	78	0	Yes

Procesamiento, cuantificación



Espacio de clasificación 2D



Métrica de distancia

FORMULA

Euclidean Distance

COLUMN 1 COLUMN 2 COLUMN 3

X x_1 x_2 x_3

Y y_1 y_2 y_3

$$\frac{(x_1 - y_1)^2 + (x_2 - y_2)^2 + (x_3 - y_3)^2}{= \text{Sum Squared}}$$

$$\text{Euclidean Distance} = \sqrt{\text{Sum Squared}}$$

EXAMPLE

Distance between ID 0 and ID 1



0 1 0 0 1.80 0.50 0

1 1 0 0 1.02 1.02 1

$$\frac{0^2 + 0^2 + 0^2 + 0.78^2 + (-0.52)^2 + 1^2}{= 1.898}$$

$$\text{Euclidean Distance} = \sqrt{1.898} = \mathbf{1.379}$$

Clasificación

Test Set (ID 14)

14	1	0	0	1.17	0.81	1

Training Set

0	1	0	0	1.80	0.50	0
1	1	0	0	1.02	1.02	1
2	0	1	1	1.49	-0.24	0
3	0	0	0	-0.56	1.66	0
⋮	⋮	⋮	⋮	⋮	⋮	⋮

Distance to ID 14

1.22
0.26
2.05
2.59
⋮

Distance to ID 14 + Label (Sorted by Distance)

	Distance to ID 14	Label
1	0.26	NO
0	1.22	NO
7	1.89	NO
11	2.02	YES
2	2.05	YES
10	2.12	YES
9	2.15	YES
12	2.21	YES
13	2.28	NO
3	2.59	YES
4	2.82	YES
8	2.86	YES
5	3.46	NO
6	3.88	YES

$k = 5$

MOST FREQUENT

NO	3
YES	2


Prediction for ID 14

14	NO
----	----

Evaluación


		$k=3$ 	$k=5$ 	$k=7$ 
14	NO	NO	NO	YES
15	YES	YES	YES	YES
16	YES	YES	YES	YES
17	NO	YES	YES	YES
18	NO	NO	NO	YES
19	NO	YES	YES	YES
20	YES	YES	YES	YES
21	YES	YES	YES	YES
22	YES	YES	YES	YES
23	YES	YES	YES	YES
24	YES	YES	YES	YES
25	YES	YES	NO	YES
26	NO	YES	YES	YES
27	YES	YES	YES	YES
Accuracy Score				

Algoritmos de inferencia






Clasificadores lineales: ¿qué línea es mejor?




Elegir el que tenga mayor margen



Parametrización del límite de decisión

- Confianza:
 $(w \cdot x_j + b) y_j$
- Etiquetas (class):
 $y_j \in \{-1, +1\}$




Maximizando el margen

- Distancia de ejemplos más cercanos desde la línea/hiperplano.
margen = γ

$$\max_{w,b} \gamma = a / \|w\|$$


$$(w \cdot x_j + b)y_j \geq a \quad \forall j$$

- Tener en cuenta que 'a' es arbitraria




Vectores de soporte

- El hiperplano lineal se define por "vectores de soporte".
- Mover un poco otros puntos no afecta el límite de decisión.
- Sólo es necesario almacenar los vectores de soporte para predecir etiquetas de nuevos puntos.



¿Qué pasa con varias clases?




Solución a problemas multiclase

- Aprender 3 clasificadores por separado:
Clase k vs el resto


$$(w_k, b_k)_{k=1,2,3}$$

$$y = \arg \max_k w_k \cdot x + b_k$$


- Pero es posible que w_k no se base en la misma escala.
- Nota: $(aw).x + (ab)$ también es una solución.



Algoritmos de inferencia



Algoritmos de inferencia



¿Preguntas?

hussein@cicese.mx

