



Curso IA desde Cero

Dr. Irvin Hussein López Nava
M.C. Joan M. Raygoza Romero

Departamento de Ciencias de la Computación
Centro de Investigación Científica y de Educación Superior de Ensenada
Edición 2026


CICESE EDUCACIÓN CONTINUA | FÍSICA APLICADA

IA desde Cero: Un Curso Práctico

Fechas: Del **4 de mayo** al **3 de junio**
Costo de Recuperación \$1,200 pesos
¿Te interesa asistir?
Escribe al siguiente correo o escanea el QR

cursosdfa@cicese.edu.mx

Más informes.



¿Qué es el
lenguaje?

lenguaje

Artículo

Sinónimos o afines

Del occit. *lenguatge*.

1. m. Facultad del ser humano de expresarse y comunicarse con los demás a través del sonido articulado o de otros sistemas de signos.
2. m. **lengua** (ll sistema de comunicación verbal).
SIN.: **lengua**, **idioma**.
3. m. Manera de expresarse. *Lenguaje culto, grosero, sencillo, técnico, forense, vulgar*.
SIN.: **habla**, **jerga**², **jerigonza**, **estilo**.
4. m. Estilo y modo de hablar y escribir de cada persona en particular.
5. m. Conjunto de señales que dan a entender algo. *El lenguaje de los ojos, el de las flores*.
6. m. Código de signos. *Lenguaje formal*.
SIN.: **código**.
7. m. **Inform**. Conjunto de signos y reglas que permite la comunicación con una computadora.


Tipos de lenguajes

Natural




- Uso humano
- Cotidiano
- Flexible, evolutivo
- e.g. Español, Inglés

Formal



- Reglas estrictas, preciso
- Sin ambigüedad
- Estructura lógica abstracta
- e.g., álgebra, lógica

Visual



- Mensajes sin palabras
- Símbolos, gestos
- Interpretación contextual
- e.g., señales, emojis


Programación



- Instrucciones para computadoras
- Sintaxis definida
- compilado o interpretado
- e.g., python, R

¿Por qué usamos el lenguaje?

- Para explicar ideas y conceptos complejos.
- Para gestionar recursos humanos, negociar, convencer, dar a conocer nuestras necesidades
- Para expresar nuestros sentimientos, contar historias, transmitir nuestra cultura a las generaciones venideras.



¿Qué busca hacer la IA?

Proporcionar medios de ampliar y mejorar la utilización del lenguaje:

- entre humanos, y
- entre humanos y computadoras




¿Cómo hacerlo?

- Por medio de emplear los vastos conocimientos acumulados por la investigación sobre las lenguas y su funcionamiento.
- Utilizando recursos lingüísticos como los diccionarios y gramáticas electrónicas y los corpus terminológicos elaborados a lo largo del tiempo.
- Con métodos que aprenden lo que se ha expresado por medio del lenguaje.

Las tecnologías del lenguaje (TLH) son el conjunto de conocimientos y medios involucrados en el **tratamiento automático del** medio de transmisión de información más complejo de nuestro planeta: **el lenguaje humano.**

¿Cómo surgen las TLH?

- Grandes repositorios de información accesibles a través del internet.
- Pero es información en su mayoría desorganizada, ¿cómo encontrar lo que se busca?



Dos grandes enfoques de las TLH

Entender el lenguaje

- Llegar a través de las palabras al contenido del mensaje

Manipular el lenguaje

- Aprovechar las regularidades del lenguaje para tratarlo



¿Por qué son importantes las TLH?

- Predicción de texto
- Reconocimiento de texto escrito a mano (*handwriting*)
- Máquinas de búsqueda que nos permiten acceder a información no estructurada
- Sistemas de traducción automática
- Asistentes virtuales
- ...

Interfaces
hombre-máquina

Gestión de
Información

Traducción de
lenguas humanas

Desarrollo de aplicaciones
con capacidad lingüística

Herramientas de
adquisición de
corpus

Corpus
Multimodales

Léxicos

Gramáticas

Diccionarios
Morfológicos

Diccionarios de
combinaciones de
palabras

Producción de
recursos
lingüísticos

Desarrollo de
tecnologías
generadoras

Investigación

Traducción
automática

Reconocimiento de
voz

Recuperación de
información

Sistemas de diálogo

Reconocimiento de
escritura

Minería de texto

Síntesis de voz

Entendimiento del
lenguaje natural

Procesamiento del Lenguaje Natural

Área de la Inteligencia Artificial y la Lingüística

- Teorías y algoritmos de aprendizaje computacional
- Teorías y recursos lingüísticos

Entre sus objetivos se encuentran:

- Entender el lenguaje, y con ello indirectamente el pensamiento (lingüística computacional)
- Construir aplicaciones relacionadas con el uso, escrito y oral, del lenguaje natural

Enfoque actual:
Lingüística basada
en Corpus

Corpus

- Es un amplio conjunto de textos –guardado en forma electrónica– evidenciando ejemplos reales del uso de una lengua: DATOS.
- Los **corpus textuales** se erigen como uno de los recursos fundamentales de la ingeniería lingüística o de las tecnologías del lenguaje.
- Dichos recursos se vuelven indispensables para la creación de sistemas prácticos de PLN.

Lingüística
Forense

¿Es esta nota de
suicidio real?

¿Cuáles son las preferencias
de los clientes?

Procesamiento del
Lenguaje Natural

¿Ha sido escrito este texto
por quien dice haberlo
hecho?

Atribución de
Autoría

Paráfrasis

Análisis de
Opinión

Similitud de
textos

Categorización

Generación de resúmenes
(uno o múltiples documentos)

¿ha hecho trampa
este estudiante?

Perfilado de
Autores

Detección de
Plagio

Agrupamiento

Identificación de
duplicados cercanos

¿Comparten contenido
dos o más sitios web?

Identificación de
las intenciones
de búsqueda

¿es apropiado para
una audiencia x?

Reformulación de
consultas

Recuperación de
Información

Campos de estudios
Preguntas
Técnicas/tareas

Algunos problemas en TLH

Lenguaje escrito: texto

Algunos problemas donde se manipulan/tratan textos

Problema	Instancia (entrada)	Objetivo (salida)
<i>Tagging</i>	Palabras en un contexto	Etiquetas
<i>Word sense disambiguation</i>	Palabras en un contexto	Word senses
<i>Language identification</i>	Texto	Languages
<i>Text classification</i>	Documentos	Topics
<i>Summarization</i>	Documentos	Short summary
<i>Information extraction</i>	Documentos	Who, when, what, ...
<i>Information retrieval</i>	Documentos	List of relevant documents

Regresando al aprendizaje supervisado

Es una función h que mapea datos de entrada X a un etiqueta (clase) y de un conjunto fijo de posibles clases.

$$X \Rightarrow y$$


Donde X es un conjunto de instancias x expresadas en forma de vector y la función aprendida puede responder consultas del tipo:

$$h(x)=y$$

$$h(\text{) = \text{gato}$$


Un nuevo caso

Ejemplo	Representación X	Etiqueta Y
	$x_1 = \langle \text{rojo}, 5\text{cm}, 5.5\text{cm}, 70\text{g} \rangle$	manzana
	$x_2 = \langle \text{amarillo}, 3\text{cm}, 4\text{cm}, 50\text{g} \rangle$	limón
	$x_3 = \langle \text{verde}, 5\text{cm}, 5.3\text{cm}, 75\text{g} \rangle$	manzana
	$x_4 = \langle \text{naranja}, 6\text{cm}, 6\text{cm}, 90\text{g} \rangle$	naranja



Datos etiquetados

Dato




Lenna




Auto



Saludo





Normal



Matemáticas

Usualmente los datos se representan como vectores numéricos
y las etiquetas se discretizan con números entre 1 y K

Datos etiquetados




X




Lenna




Auto



Saludo



Normal



Matemáticas

Y

1

24

-1

0

3

X

Y



1

La **pregunta** ahora es

¿Cómo pasar el DATO a un vector numérico
(que la computadora entienda)
y las etiquetas a números?

Datos etiquetados

Los **datos** se representan por un conjunto de atributos o mediciones.



Instancia:

Atributos:

Etiqueta:



Instancia:

Atributos:

Etiqueta:

Datos etiquetados


Los **datos** se representan por un conjunto de atributos o mediciones.



Instancia: Fruta

Atributos: color, alto, ancho, masa

Etiqueta: manzana



Instancia: Imagen RGB

Atributos: textura, intensidad, brillo, etc.

Etiqueta: mujer

Datos etiquetados

Los **datos** se representan por un conjunto de atributos o mediciones.

La Máquina estuvo muy cerca de abrir el marcador por primera vez en la serie, pero una vez más Keylor Navas se mostró sólido bajo los tres palos hasta en dos ocasiones. Solo un error en territorio cruzazulino podía abrir la puerta para que Pumas anotara primero y así fue.

A la media hora de juego, un error en el medio campo permitió el contragolpe de Robert Morales, quien tras conducir y pasar para una serie de rebotes el balón regresó a los pies del paraguayo, quien de primera definió cruzado para hacer explotar al Olímpico Universitario.

La desgracia llegó para Pumas a los 55 minutos del complemento con el autogol de Rubén Duarte al cruzarse en el camino del despeje de Nathan Silva que había cortado un centro raso al corazón del área. La afición universitaria recibió un segundo golpe al ánimo cuando 'Coco' Carrasquilla tuvo que salir del partido por una lesión muscular que dejó desprovisto el mediocampo.

El panorama para Universidad se volvió aún más gris a minutos del final de los 90 minutos con la entrada de Uriel Antuna sobre Jeremy Márquez que sin duda era meritoria de expulsión. Sobre la hora, un gol de Rotondi acabó con el sueño universitario y la alegría para los cruzazulinos de poder levantar su décimo título.

Instancia:

Atributos:

Etiqueta:

Datos etiquetados

Los **datos** se representan por un conjunto de atributos o mediciones.

La Máquina estuvo muy cerca de abrir el marcador por primera vez en la serie, pero una vez más Keylor Navas se mostró sólido bajo los tres palos hasta en dos ocasiones. Solo un error en territorio cruzazulino podía abrir la puerta para que Pumas anotara primero y así fue.

A la media hora de juego, un error en el medio campo permitió el contragolpe de Robert Morales, quien tras conducir y pasar para una serie de rebotes el balón regresó a los pies del paraguayo, quien de primera definió cruzado para hacer explotar al Olímpico Universitario.

La desgracia llegó para Pumas a los 55 minutos del complemento con el autogol de Rubén Duarte al cruzarse en el camino del despeje de Nathan Silva que había cortado un centro raso al corazón del área. La afición universitaria recibió un segundo golpe al ánimo cuando 'Coco' Carrasquilla tuvo que salir del partido por una lesión muscular que dejó desprovisto el mediocampo.


El panorama para Universidad se volvió aún más gris a minutos del final de los 90 minutos con la entrada de Uriel Antuna sobre Jeremy Márquez que sin duda era meritoria de expulsión. Sobre la hora, un gol de Rotondi acabó con el sueño universitario y la alegría para los cruzazulinos de poder levantar su décimo título.

Instancia: Documento de texto

Atributos: ??

Etiqueta: Deportes

Enfoques de aprendizaje



Representación

color: categórico,
altura: continuo (cm),
anchura: continuo (cm),
masa: continuo (g)

Ejemplo	Representación X	Etiqueta Y
	$x_1 = \langle \text{rojo}, 5\text{cm}, 5.5\text{cm}, 70\text{g} \rangle$	manzana
	$x_2 = \langle \text{amarillo}, 3\text{cm}, 4\text{cm}, 50\text{g} \rangle$	limón
	$x_3 = \langle \text{verde}, 5\text{cm}, 5.3\text{cm}, 75\text{g} \rangle$	manzana
	$x_4 = \langle \text{naranja}, 6\text{cm}, 6\text{cm}, 90\text{g} \rangle$	naranja



	t_1	t_2	t_3	t_4
x_1	rojo	5	5.5	70
x_2	amarillo	3	4	50
x_3	verde	5	5.3	75
x_4	naranja	6	6	90

Representación vectorial


Atributos

¿cuáles son unos buenos atributos?

¿cómo se seleccionan?

Instancias

Un documento por fila



The diagram shows a matrix with rows representing documents and columns representing attributes. A blue bracket on the left groups the rows under the label 'Instancias'. A blue bracket on top groups the columns under the label 'Atributos'. The matrix has columns labeled t_1 , t_2 , $\dots$, and t_n . The rows are labeled d_1 , d_2 , $\dots$, and d_m . The cell at the intersection of row d_2 and column t_2 contains the weight w_{ij} . An arrow points from this cell to a text box on the right.

	t_1	t_2	$\dots$	t_n
d_1				
d_2		w_{ij}		
$\dots$				
d_m				

**Peso del atributo j
en un documento i**

¿Cómo determinar la
importancia de un atributo?

¿Cómo se calcula el peso de un atributo en un documento?

La importancia del término puede ser proporcionalmente al **número de veces** que aparece en el documento.

- Este enfoque ayuda a **describir** el contenido del documento.

La importancia general de un término decrementa proporcionalmente a la ocurrencia de la colección completa.

- Términos comunes no son buenos para **discriminar** entre las clases de objetos.

Esquemas de pesado

- Pesado booleano

- $w_{ij} = 1$, sí y solo sí el documento i contiene el término j , en caso contrario, es 0.

- Frecuencia del término (tf)

- $w_{ij} =$ número de ocurrencias de t_j en d_i

- tf x idf

- $w_{ij} = \text{tf}(t_j, d_i) \times \text{idf}(t_j)$
- $\text{tf}(t_j, d_i)$ indica la ocurrencia de t_j en el documento d_i
- $\text{idf}(t_j) = \log [N/\text{df}(t_j)]$, donde $\text{df}(t_j)$ es el número de documento que contienen el término t_j .

¿Cómo pasar un texto a un vector de características?

El enfoque más sencillo es una representación basada en una bolsa de palabras BOW (*bag of words*) y las frecuencias de estas palabras en cada documento.

Ejemplos:

x_1 : "y mi voz que madura"

x_2 : "y mi voz quemadura"

x_3 : "y mi bosque madura"

x_4 : "y mi voz quema dura"


y: 4	mi: 4	voz: 3	que: 1	madura: 2	quemadura: 1	bosque: 1	quema: 1	dura: 1
------	-------	--------	--------	-----------	--------------	-----------	----------	---------

¿Cómo pasar un texto a un vector de características?

	y	mi	voz	que	madura	quemadura	bosque	quema	dura
“y mi voz que madura”	1	1	1	1	1	0	0	0	0
“y mi voz quemadura”	1	1	1	0	0	1	0	0	0
“y mi bosque madura”	1	1	0	0	1	0	1	0	0
“y mi voz quema dura”	1	1	1	0	0	0	0	1	1


Problemas generales de la representación BoW

- Se filtran términos de palabras comunes
- Hay palabras que aparecen poco y que pueden no ser relevantes para nuestra tarea.
- Al ser una bolsa de palabras, no existe un orden en las palabras que aparecen en el texto.



Filtrar palabras más comunes

- Listas de STOPWORDS. Son palabras funcionales, por ejemplo artículos, conectores, etc. Ocurren con mucha frecuencia en la mayoría de los documentos, no ayudan a discriminar el tema de un texto, por ejemplo.



Mucha ocurrencia vs poca ocurrencia

- Eliminar términos por frecuencia máxima (si ocurre más de n veces, dejarlas)
- Podemos eliminar palabras que aparecen poco.
 - Corte *cut-off*: se debe determinar cuál es la frecuencia mínima de un término para ser considerado dentro de la representación.
- Eliminar palabras del problema que no queremos que se consideren (dependiendo del dominio del problema).

n-gramas

Podemos agregar nuevos términos que considera, hasta cierto punto, el orden de algunas palabras:

- **Bigramas:** palabras de dos en dos
- **Trigramas:** palabras de tres en tres
- **n-gramas:** palabras de n en n

“y mi voz que madura”

- **Bigramas:**
- **Trigramas:**

n-gramas

Podemos agregar nuevos términos que considera, hasta cierto punto, el orden de algunas palabras:

- **Bigramas:** palabras de dos en dos
- **Trigramas:** palabras de tres en tres
- **n-gramas:** palabras de n en n

“y mi voz que madura”

- **Bigramas:** y-mi, mi-voz, voz-que, que-madura
- **Trigramas:** y-mi-voz, mi-voz-que, voz-que-madura

El lenguaje es complejo: **polisemia**

Carta



Banco



Planta



Polo



El lenguaje es complejo: **sinonimia**



¿Preguntas?

husein@cicese.mx

